IBM Telco Customer Churn

生存分析报告

Survival Analysis Report

李雨晨 12310843

2026 年 4 月 26 日

1 项目概述

本报告使用 **PySpark + Python (lifelines)** 对 IBM Telco 客户流失数据进行生存分析（Survival Analysis）。通过对客户”存活时间”（tenure，在网月数）与”流失事件”（churn）的建模，识别影响客户流失的关键因素，并对客户终身价值（CLV）和投资回收期（Payback Period）进行估算。

分析流程：

1. 数据导入与 Bronze/Silver 分层清洗
2. Kaplan-Meier 生存曲线估计 + Log-rank 检验
3. Cox Proportional Hazards 模型
4. AFT (Accelerated Failure Time) 模型
5. CLV / Payback Period 计算

2 数据说明

2.1 数据来源

数据集为 **IBM Telco Customer Churn**（`Telco-Customer-Churn.csv`），包含 7,043 条客户记录，涵盖人口统计信息、服务订阅信息和账单信息等 21 个字段。

2.2 数据清洗（Bronze → Silver）

数据清洗采用 **Medallion Architecture**（Bronze–Silver 分层）：

1. **Bronze 层**：以预定义的 21 列 Schema 直接读取原始 CSV 文件，保留所有记录（7,043 条）。
2. **Silver 层**（`silver_monthly_customers`）进行以下筛选与转换：
   - 将 `Churn` 字段从 “Yes”/“No” 转换为数值 1/0
   - 仅保留 **Month-to-month（按月签约）**合同的客户
   - 仅保留 **有互联网服务**（`internetService` $\neq$ `"No"`）的客户

清洗后数据集包含 **3,351 条**客户记录，其中 1,556 人发生了流失（event），1,795 人仍在网（右侧截断，right-censored）。

2.3 核心变量

变量	说明	在生存分析中的角色
`tenure`	客户在网月数（0–72）	**生存时间（duration）**
`churn`	是否流失（1= 流失, 0= 在网）	**事件指示变量（event）**

表 1: 生存分析核心变量

为什么选择 tenure 和 churn 作为核心变量？
生存分析研究的是" 从某个起点开始，到某个事件发生的时间"。在客户流失场景中：

- `tenure` 对应生存时间：客户从入网开始观察，tenure 是已经" 存活" 的月数。
- `churn` 对应事件指示：如果客户已流失（churn=1），则 tenure 就是确切的生存时间；如果客户仍在网（churn=0），则 tenure 是一个" 最小生存时间"（右侧截断数据）。

这两个变量构成了生存分析的标准输入：`duration column` + `event column`。

3 Kaplan-Meier 生存曲线估计

3.1 总体生存曲线

使用 `KaplanMeierFitter` 对全体 3,351 名客户拟合 Kaplan-Meier 生存曲线。

- **样本量**：3,351 观测值，1,795 右侧截断
- **曲线含义**：X 轴为在网月数（tenure），Y 轴为生存概率

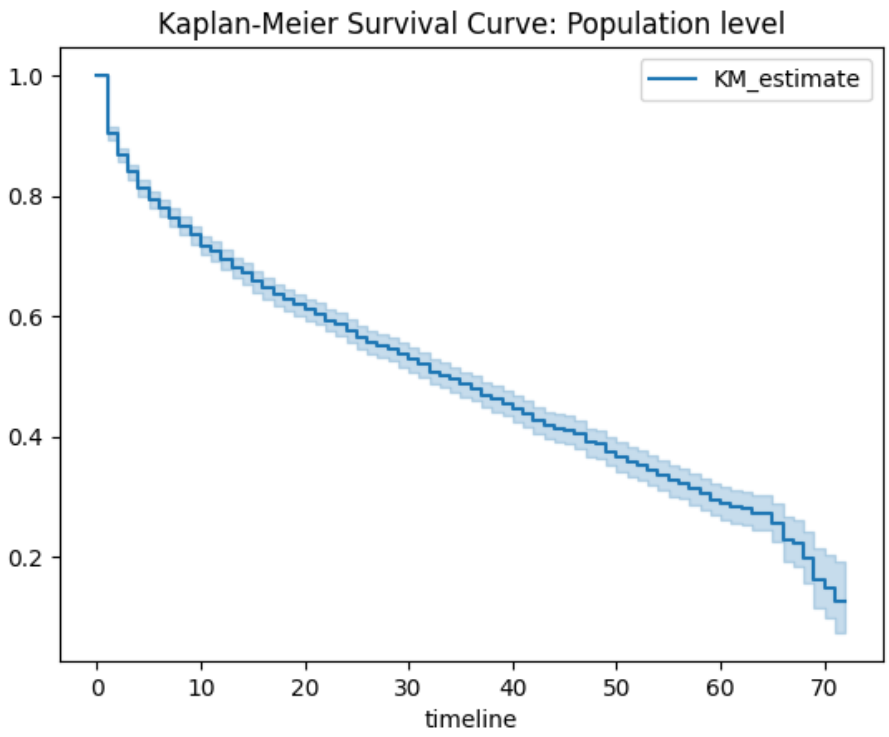

图 1: 总体 Kaplan-Meier 生存曲线

观察：总体生存曲线呈单调递减趋势，早期（1–10 个月）下降最快，说明 Month-to-month 客户在入网初期流失风险最高；随着时间推移，曲线趋于平缓，长期留存客户的流失风险降低。

3.2 分组生存曲线与 Log-Rank 检验

对 13 个分类变量分别绘制分组 Kaplan-Meier 曲线，并使用 **pairwise log-rank test** 检验组间生存差异。

3.2.1 Gender（性别）

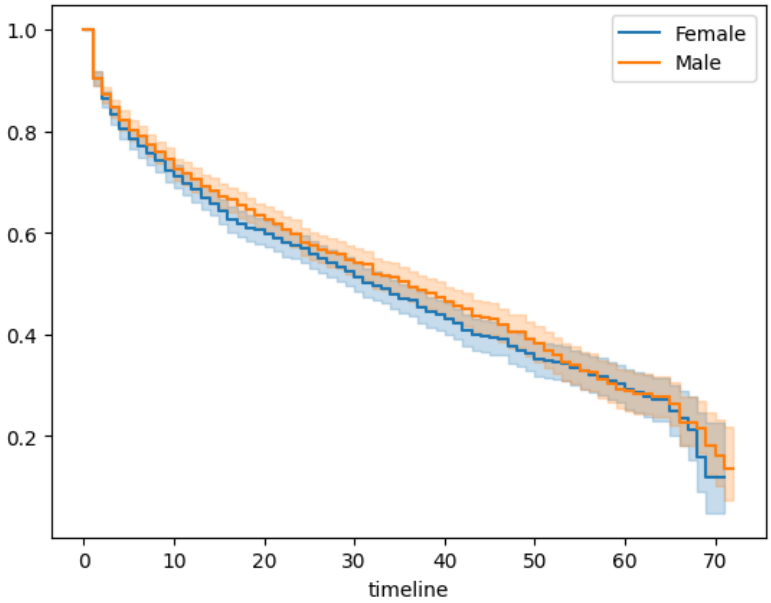

图 2: Kaplan-Meier 生存曲线 — Gender

比较	Test Statistic	p-value
Female vs Male	2.039	0.153

表 2: Log-Rank 检验 — Gender

$p = 0.153 > 0.05$，性别对流失**无显著影响**。

3.2.2 Senior Citizen（是否老年人）

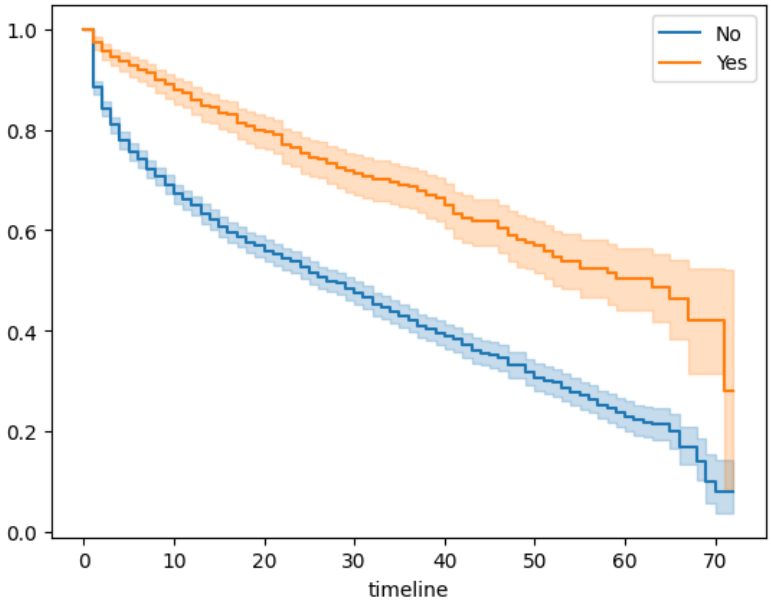

图 3: Kaplan-Meier 生存曲线 — Senior Citizen

比较	Test Statistic	p-value
0.0 vs 1.0	0.125	0.723

表 3: Log-Rank 检验 — Senior Citizen

$p = 0.723 > 0.05$，是否老年人对流失**无显著影响**。

3.2.3 Partner（是否有伴侣）

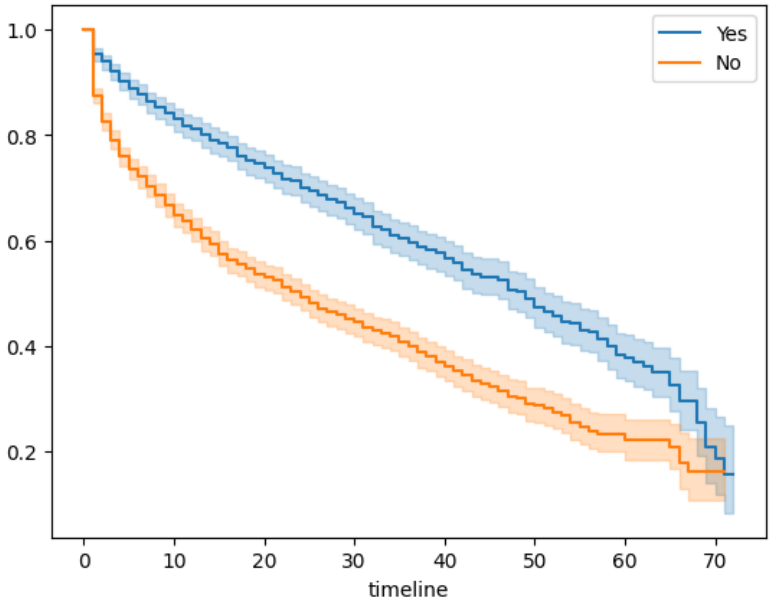

图 4: Kaplan-Meier 生存曲线 — Partner

比较	Test Statistic	p-value
No vs Yes	135.759	2.25×10^{-31}

表 4: Log-Rank 检验 — Partner

$p \approx 0$，有伴侣的客户生存概率**显著高于**无伴侣的客户。

3.2.4 Dependents（是否有家属）

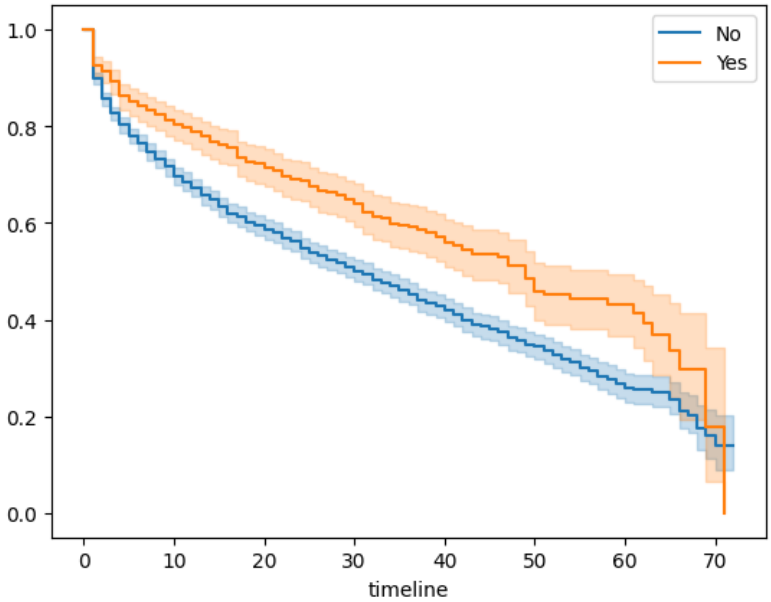

图 5: Kaplan-Meier 生存曲线 — Dependents

比较	Test Statistic	p-value
No vs Yes	35.031	3.24×10^{-9}

表 5: Log-Rank 检验 — Dependents

$p \approx 0$，有家属的客户生存概率**显著高于**无家属的客户。

3.2.5 Phone Service（电话服务）

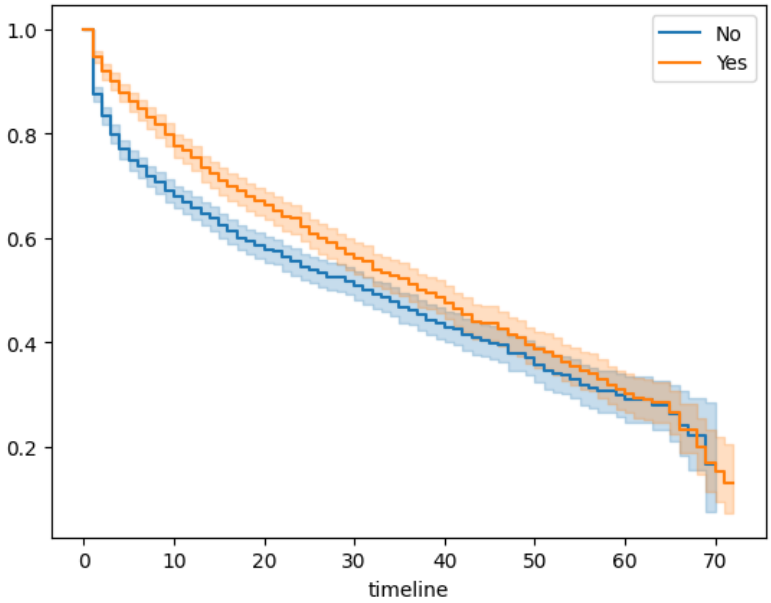

图 6: Kaplan-Meier 生存曲线 — Phone Service

比较	Test Statistic	p-value
No vs Yes	1.684	0.194

表 6: Log-Rank 检验 — Phone Service

$p = 0.194 > 0.05$，电话服务对流失**无显著影响**。

3.2.6 Multiple Lines（多线路）

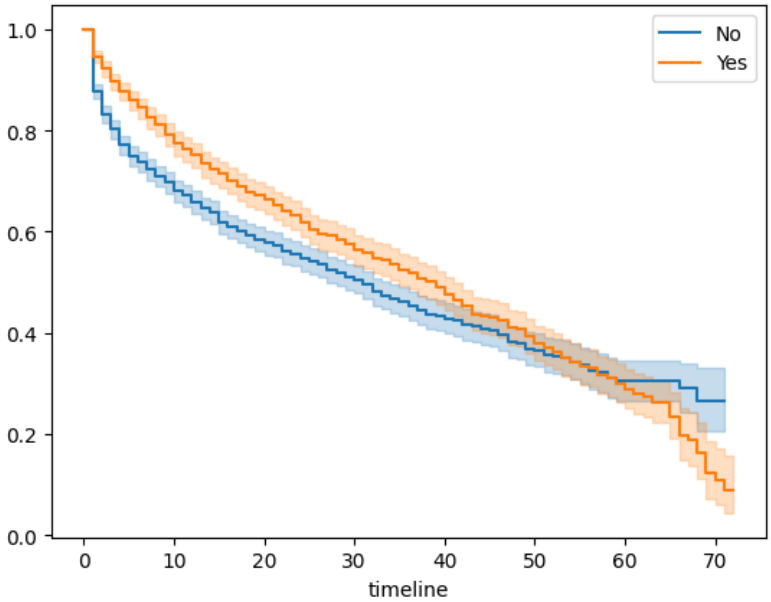

图 7: Kaplan-Meier 生存曲线 — Multiple Lines

比较	Test Statistic	p-value
No vs No phone service	12.383	4.33×10^{-4}
No vs Yes	72.358	1.79×10^{-17}
No phone service vs Yes	1.500	0.221

表 7: Log-Rank 检验 — Multiple Lines

No vs Yes 高度显著（$p < 0.001$），说明有/无多线路服务的客户生存差异显著。

3.2.7 Internet Service（互联网服务类型）

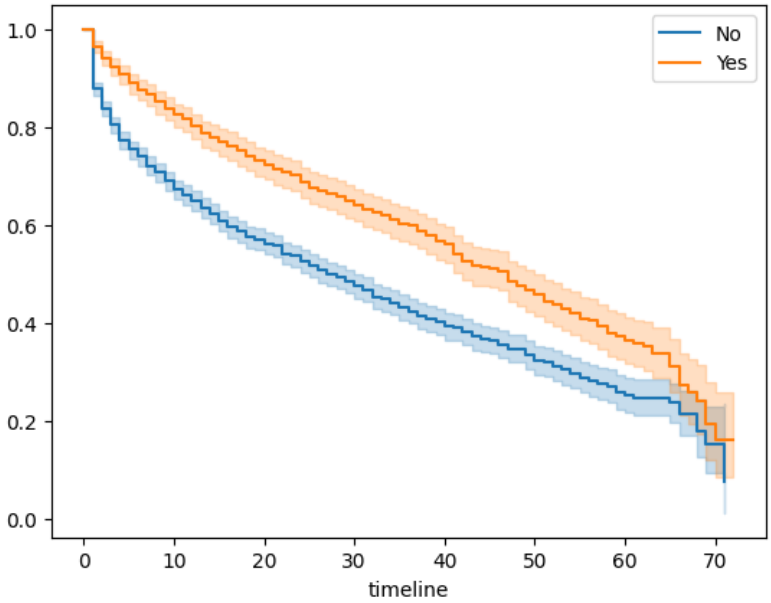

图 8: Kaplan-Meier 生存曲线 — Internet Service

比较	Test Statistic	p-value
DSL vs Fiber optic	25.173	5.24×10^{-7}

表 8: Log-Rank 检验 — Internet Service

$p < 0.001$，DSL 与 Fiber optic 客户生存差异**高度显著**，DSL 客户留存概率更高。

3.2.8 Online Security（在线安全服务）

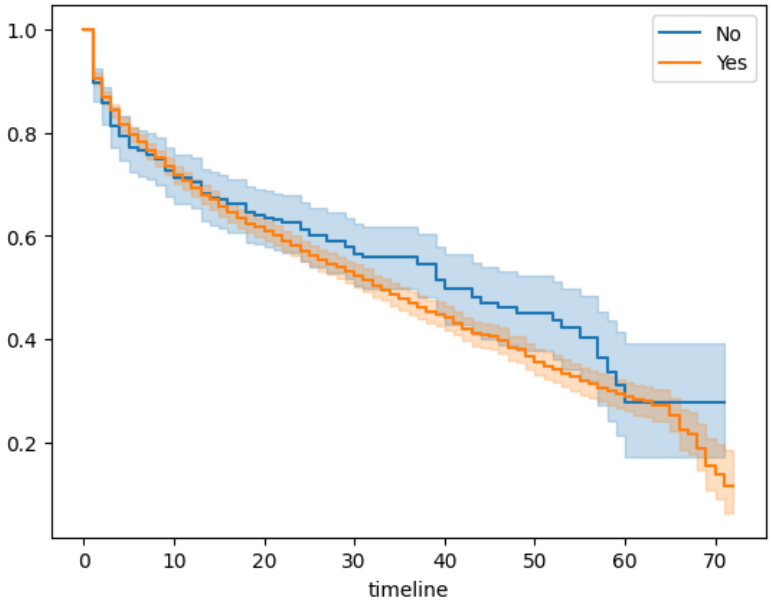

图 9: Kaplan-Meier 生存曲线 — Online Security

比较	Test Statistic	p-value
No vs Yes	**141.603**	$\mathbf{1.19 \times 10^{-32}}$

表 9: Log-Rank 检验 — Online Security

在线安全服务是对客户留存影响最大的变量（$p = 1.19 \times 10^{-32}$，所有变量中最低），有在线安全服务的客户生存概率显著高于没有的客户。

3.2.9 Tech Support（技术支持）

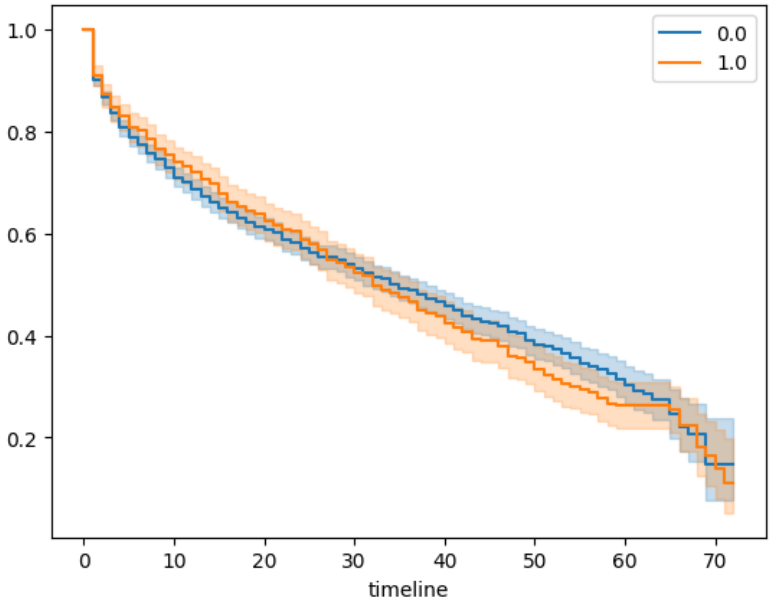

图 10: Kaplan-Meier 生存曲线 — Tech Support

比较	Test Statistic	p-value
No vs Yes	**90.430**	$\mathbf{1.92 \times 10^{-21}}$

表 10: Log-Rank 检验 — Tech Support

$p \approx 0$，技术支持是极强的保护因子。

3.2.10 Device Protection（设备保护）

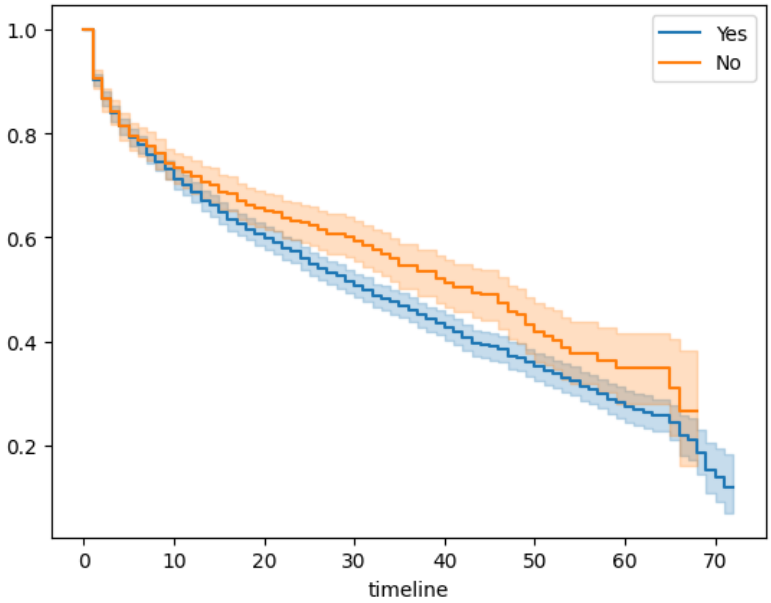

图 11: Kaplan-Meier 生存曲线 — Device Protection

比较	Test Statistic	p-value
No vs Yes	71.497	2.78×10^{-17}

表 11: Log-Rank 检验 — Device Protection

高度显著（$p < 0.001$），有设备保护的客户留存更好。

3.2.11 Streaming TV

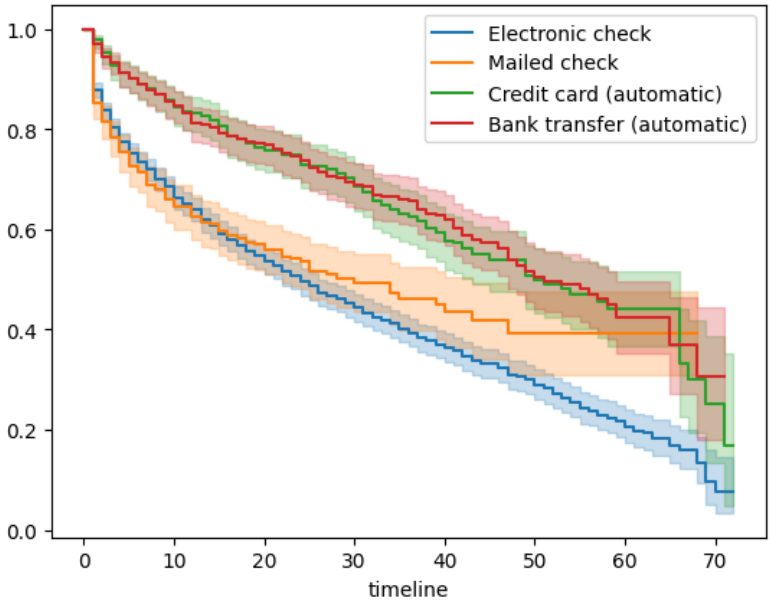

图 12: Kaplan-Meier 生存曲线 — Streaming TV

比较	Test Statistic	p-value
No vs Yes	12.939	3.22×10^{-4}

表 12: Log-Rank 检验 — Streaming TV

显著（$p < 0.001$）。

3.2.12 Streaming Movies

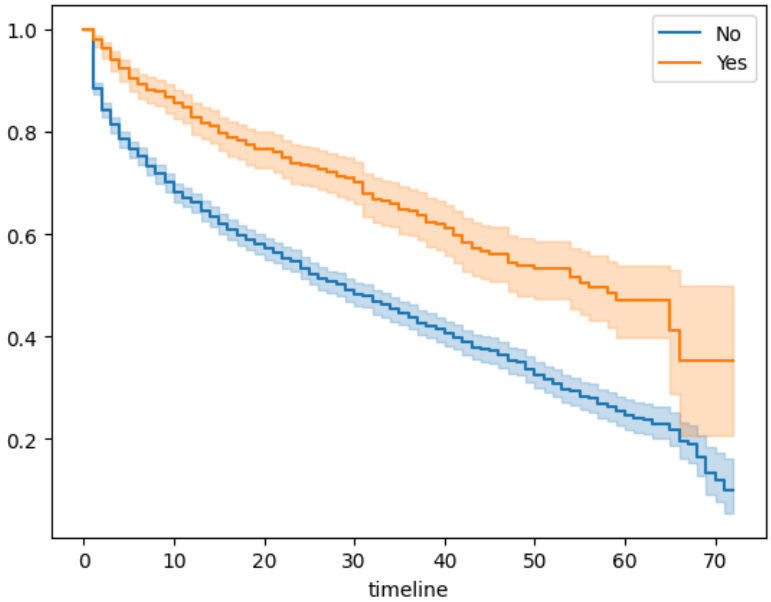

图 13: Kaplan-Meier 生存曲线 — Streaming Movies

比较	Test Statistic	p-value
No vs Yes	17.942	2.30×10^{-5}

表 13: Log-Rank 检验 — Streaming Movies

显著（$p < 0.001$）。

3.2.13 Paperless Billing（无纸账单）

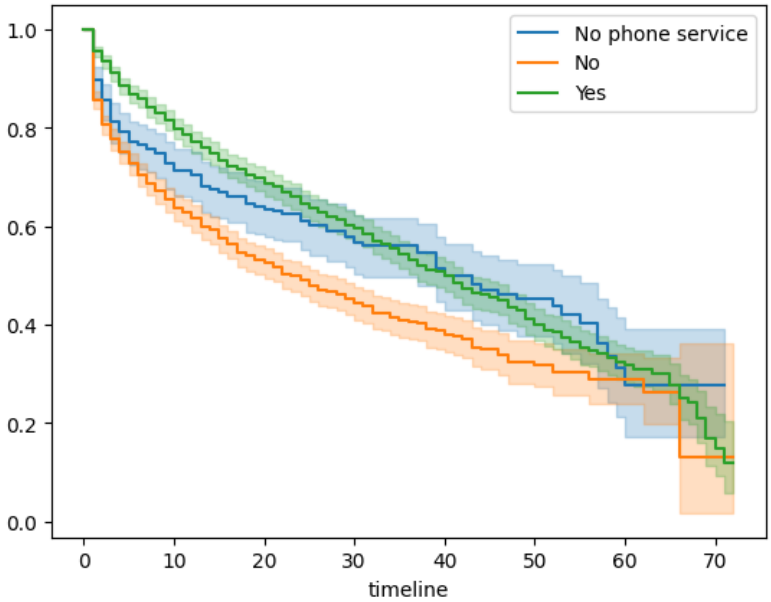

图 14: Kaplan-Meier 生存曲线 — Paperless Billing

比较	Test Statistic	p-value
No vs Yes	8.341	0.0039

表 14: Log-Rank 检验 — Paperless Billing

显著（$p = 0.0039 < 0.05$）。

3.2.14 Payment Method（支付方式）

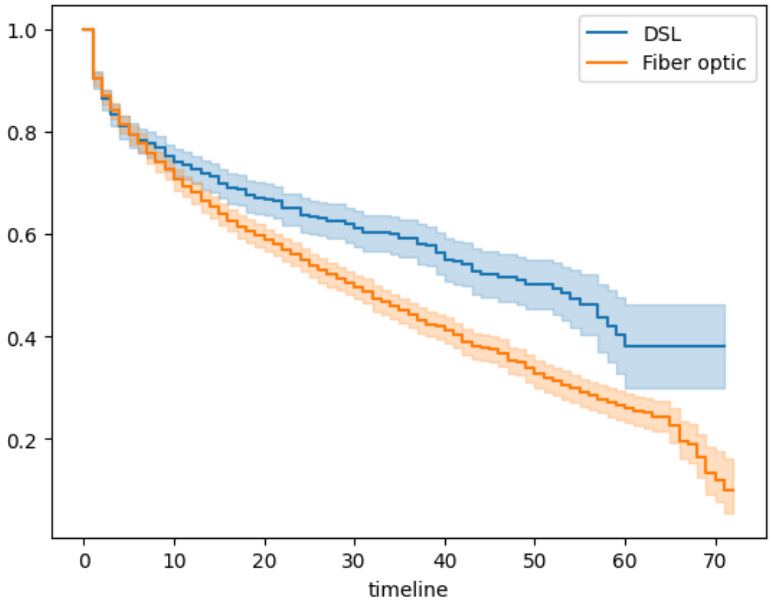

图 15: Kaplan-Meier 生存曲线 — Payment Method

比较	Test Statistic	p-value
Bank transfer vs Credit card	0.062	0.804
Bank transfer vs Electronic check	91.192	1.30×10^{-21}
Bank transfer vs Mailed check	43.537	4.16×10^{-11}
Credit card vs Electronic check	79.991	3.76×10^{-19}
Credit card vs Mailed check	39.685	2.98×10^{-10}
Electronic check vs Mailed check	0.898	0.343

表 15: Log-Rank 检验 — Payment Method

使用 Electronic check 支付的客户流失风险**显著高于** Bank transfer 和 Credit card 自动支付客户。

3.3 Log-Rank 检验结果汇总

变量	Test Statistic	p-value	显著
gender	2.04	0.153	×
seniorCitizen	0.13	0.723	×
partner	135.76	2.25×10^{-31}	✓
dependents	35.03	3.24×10^{-9}	✓
phoneService	1.68	0.194	×
multipleLines (No vs Yes)	72.36	1.79×10^{-17}	✓
internetService	25.17	5.24×10^{-7}	✓
streamingTV	12.94	3.22×10^{-4}	✓
streamingMovies	17.94	2.30×10^{-5}	✓
onlineSecurity	**141.60**	$\mathbf{1.19 \times 10^{-32}}$	✓
deviceProtection	71.50	2.78×10^{-17}	✓
techSupport	**90.43**	$\mathbf{1.92 \times 10^{-21}}$	✓
paperlessBilling	8.34	0.0039	✓
paymentMethod (key pairs)	79.99	3.76×10^{-19}	✓

表 16: Log-Rank 检验结果汇总 ($\alpha = 0.05$)

关键发现：在线安全服务（onlineSecurity）是影响最大的变量，其次是技术支持（techSupport）。性别和是否老年人对流失无显著影响。

3.4 DSL 客户生存概率

以 `internetService = DSL` 为例，提取 0–9 个月的生存概率：

月份	0	1	2	3	4	5	6	7	8	9
生存概率	1.000	0.903	0.864	0.835	0.811	0.794	0.784	0.776	0.768	0.751

表 17: DSL 客户月度生存概率

DSL 客户在入网第 1 个月就有约 10% 的流失率，到第 9 个月存活率约 75%。

4 Cox 比例风险模型

4.1 模型设定

使用 `CoxPHFitter` 拟合 Cox 比例风险模型，包含 4 个协变量：

- `dependents_Yes`：是否有家属
- `internetService_DSL`：是否使用 DSL
- `onlineBackup_Yes`：是否有在线备份

- `techSupport_Yes`：是否有技术支持

指标	值
观测数	3,351
事件数	1,556
偏对数似然	$-11,315.95$
Concordance	0.64

表 18: Cox PH 模型拟合信息

4.2 Cox PH 模型与 PH 假设概念图

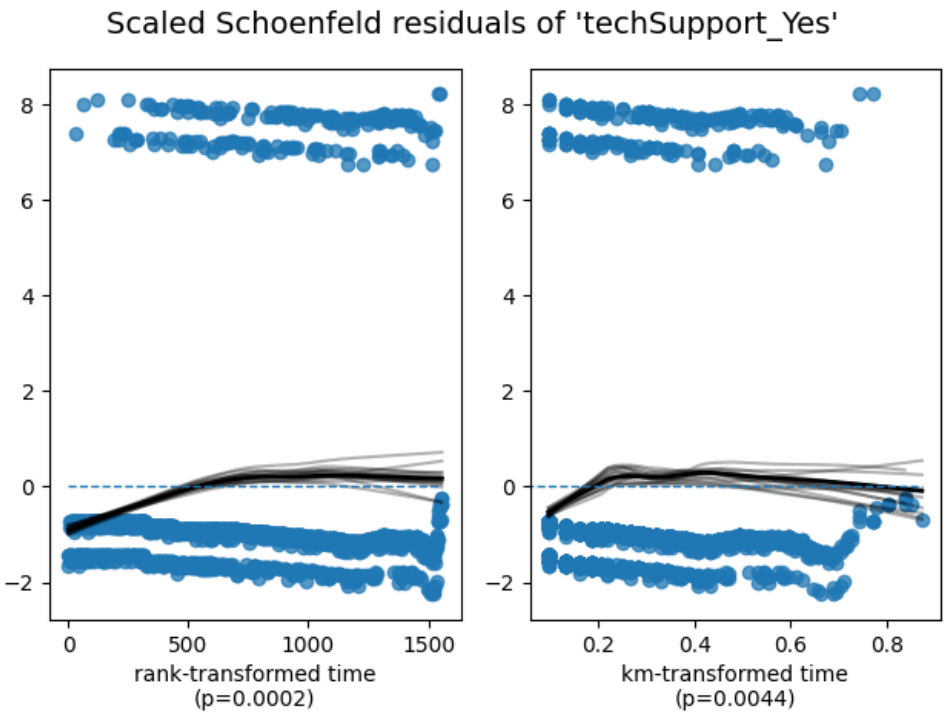

图 16: 比例风险假设概念说明

左侧图展示了满足比例风险假设的情况（两条曲线平行），右侧为不满足的情况（曲线发散）。

4.3 模型结果

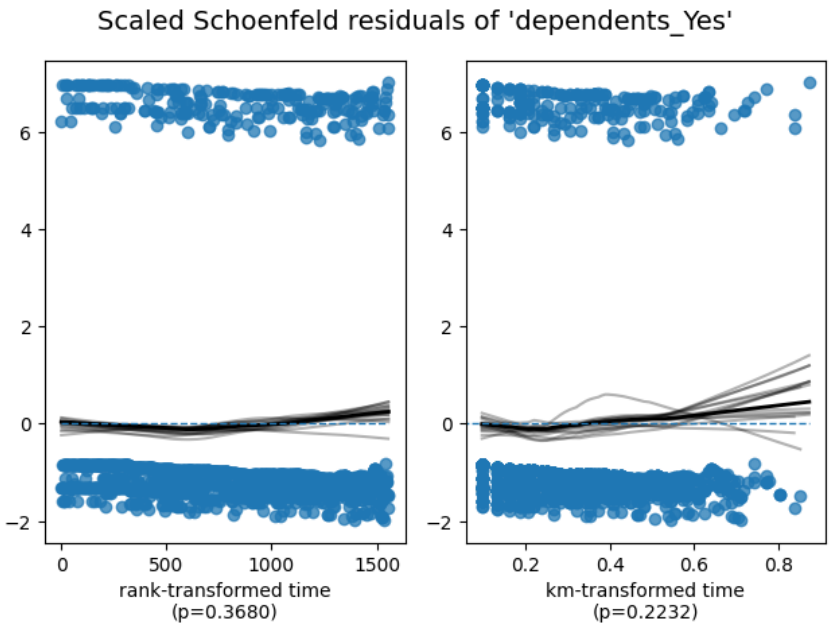

图 17: Cox PH 模型 Hazard Ratios 及 95% 置信区间

协变量	系数	HR	95% CI	p-value	解释
dependents_Yes	-0.33	**0.72**	$[0.63, 0.83]$	< 0.005	流失风险 ↓28%
internetService_DSL	-0.22	**0.80**	$[0.72, 0.90]$	< 0.005	流失风险 ↓20%
onlineBackup_Yes	-0.78	**0.46**	$[0.41, 0.52]$	< 0.005	流失风险 ↓54%
techSupport_Yes	-0.64	**0.53**	$[0.46, 0.61]$	< 0.005	流失风险 ↓47%

表 19: Cox PH 模型回归结果

结果解读：

- 所有 4 个变量均**高度显著**（$p < 0.005$，lifelines 默认截断显示），且系数均为负值，说明这些因素都起到降低流失风险的**保护作用**。
- **在线备份（onlineBackup）**的保护效果最强（HR = 0.46），其次是技术支持（techSupport, HR = 0.53）。
- Concordance index 为 0.64，具有一定的预测区分能力。

4.4 比例风险假设检验

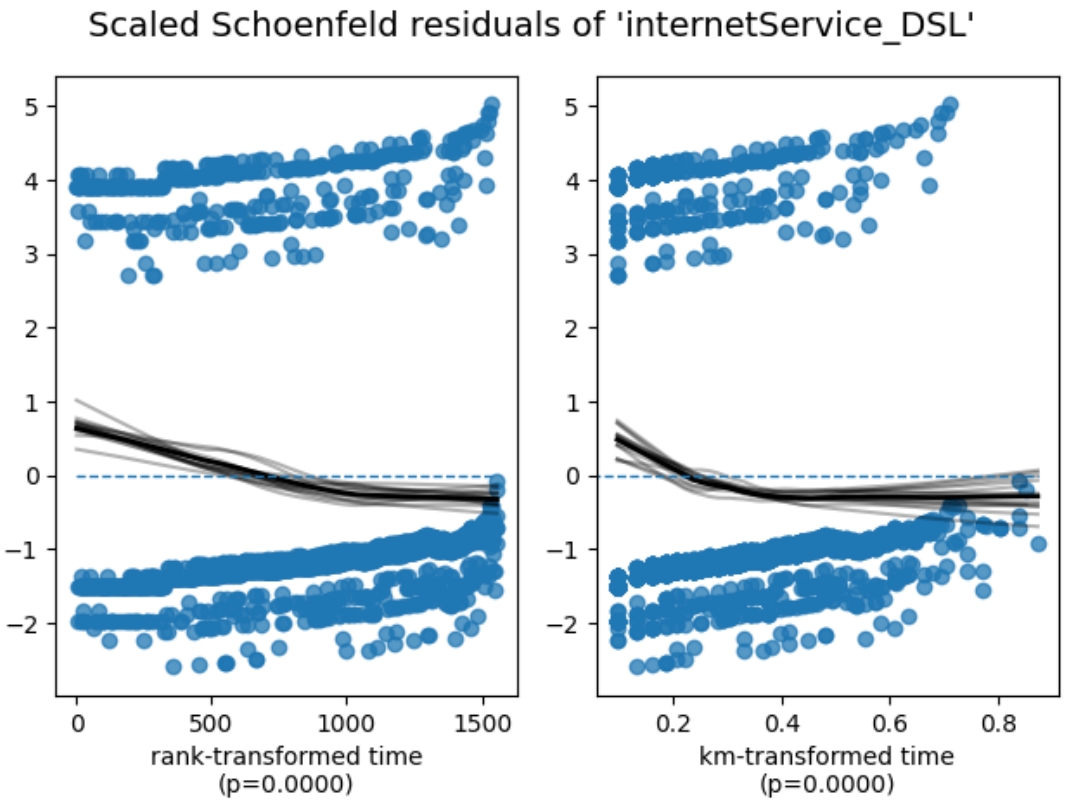

图 18: 比例风险假设检验（Schoenfeld Residuals）

变量	p-value	PH 假设
dependents_Yes	0.37	✓通过
internetService_DSL	$< 5 \times 10^{-5}$	× 未通过
onlineBackup_Yes	$< 5 \times 10^{-5}$	× 未通过
techSupport_Yes	0.004	∼ 边界

表 20: 比例风险假设检验结果

`internetService_DSL` 和 `onlineBackup_Yes` 违反了比例风险假设,建议使用分层（`strata`）修正，或采用 AFT 模型。

4.5 Log-Log 生存曲线

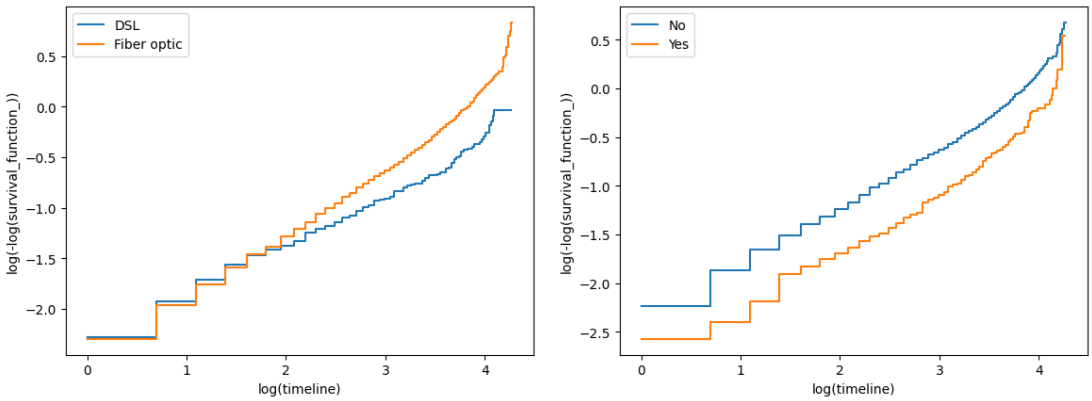

(a) internetService (b) dependents

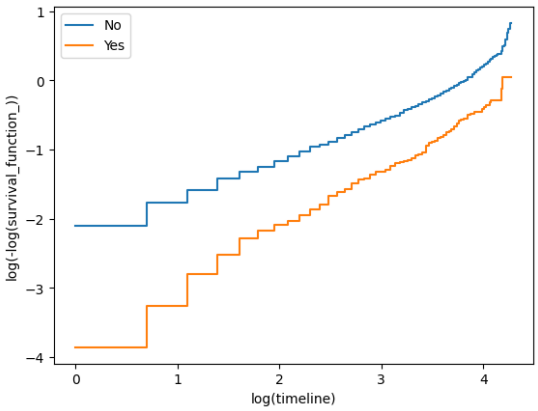

(c) techSupport

图 19: Log-Log 生存曲线

如果比例风险假设成立，各组 log-log 曲线应大致平行。`dependents` 曲线大致平行（与检验结果一致），`internetService` 和 `techSupport` 曲线后期出现分离。

5 AFT 模型（Log-Logistic）

5.1 模型选择理由

由于 Cox 模型中部分变量违反比例风险假设，采用 **Log-Logistic AFT 模型**作为补充。AFT 模型直接对生存时间建模，不依赖比例风险假设。

注意：Cox PH 模型和 AFT 模型纳入的协变量不完全相同。Cox PH 模型选取了 4 个变量（`dependents_Yes`, `internetService_DSL`, `onlineBackup_Yes`, `techSupport_Yes`），而 AFT 模型纳入了 9 个变量（增加了 `partner_Yes`, `multipleLines_Yes`, `onlineSecurity_Yes`, `deviceProtection_Yes` 以及两个 `paymentMethod` 虚拟变量）。这是因为两个模型的用途不同：Cox PH 模型侧重于识别违反比例风险假设的变量（用于诊断模型适用性），而 AFT 模型旨在更全面地量化各因素对生存时间的影响。

5.2 模型设定

包含 9 个协变量和 2 个分布参数（`alpha_`, `beta_`）：

- `partner_Yes`, `multipleLines_Yes`, `internetService_DSL`
- `onlineSecurity_Yes`, `onlineBackup_Yes`, `deviceProtection_Yes`, `techSupport_Yes`
- `paymentMethod_Bank transfer (automatic)`, `paymentMethod_Credit card (automatic)`

指标	值
观测数	3,351
事件数	1,556
对数似然	$-6,838.36$
AIC	13,698.72
中位生存时间	**135.51** 个月
Concordance	0.73
对数似然比统计量	877.49 (on 9 df, $p < 0.005$)

表 21: Log-Logistic AFT 模型拟合信息

5.3 AFT 模型系数图

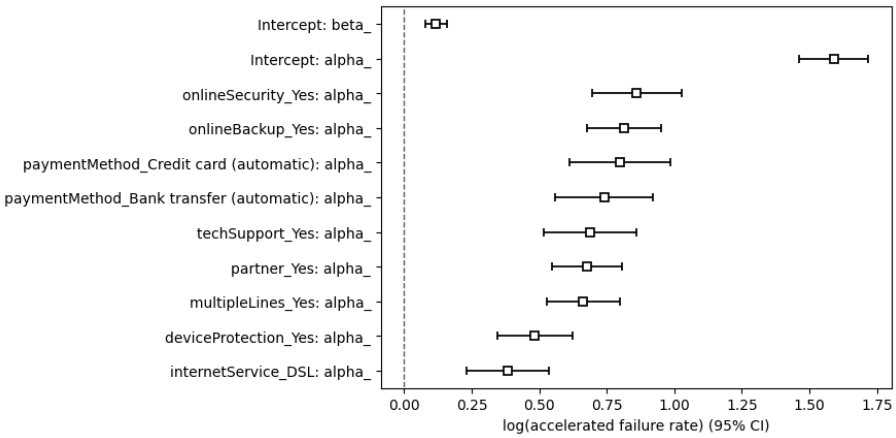

图 20: AFT 模型系数图（log(accelerated failure rate) 及 95% CI）

5.4 模型结果

参数类型	协变量	系数	exp(coef)	95% CI	p-value
alpha_	deviceProtection_Yes	0.48	1.62	$[1.41, 1.86]$	< 0.005
	internetService_DSL	0.38	1.47	$[1.26, 1.71]$	< 0.005
	multipleLines_Yes	0.66	1.94	$[1.70, 2.22]$	< 0.005
	onlineBackup_Yes	0.81	2.25	$[1.97, 2.59]$	< 0.005
	onlineSecurity_Yes	0.86	2.37	$[2.00, 2.80]$	< 0.005
	partner_Yes	0.68	1.97	$[1.73, 2.24]$	< 0.005
	paymentMethod_Bank transfer (automatic)	0.74	2.10	$[1.75, 2.51]$	< 0.005
	paymentMethod_Credit card (automatic)	0.80	2.22	$[1.84, 2.68]$	< 0.005
	techSupport_Yes	0.69	1.99	$[1.68, 2.36]$	< 0.005
alpha_	Intercept	1.59	4.91	$[4.32, 5.58]$	< 0.005
beta_	Intercept	0.12	1.13	$[1.08, 1.17]$	< 0.005

表 22: Log-Logistic AFT 模型结果

结果解读：

在 AFT 模型中，exp(coef)（alpha_ 参数）表示**时间比率（time ratio）**：

- `onlineSecurity_Yes`: TR = 2.37，有在线安全服务的客户生存时间是没在线安全服务的客户的 **2.37 倍**（该变量未纳入 Cox PH 模型，AFT 模型提供了更完整的分析视角）
- `onlineBackup_Yes`: TR = 2.25，有在线备份的客户生存时间是没在线备份的客户的 **2.25 倍**
- `paymentMethod_Credit card (automatic)`: TR = 2.22，使用 Credit card 自动支付的客户生存时间是 Electronic check 客户的 **2.22 倍**
- `techSupport_Yes`: TR = 1.99，有技术支持的客户生存时间是没技术支持的客户的 **1.99 倍**
- 与 Cox PH 模型共享的 4 个变量（`internetService_DSL`, `onlineBackup_Yes`, `techSupport_Yes`, `dependents_Yes`）方向一致，均为保护因子
- 所有变量均高度显著（$p < 0.005$）
- Concordance 为 0.73，**高于 Cox PH 模型的 0.64**

5.5 分组生存曲线（AFT 模型部分变量）

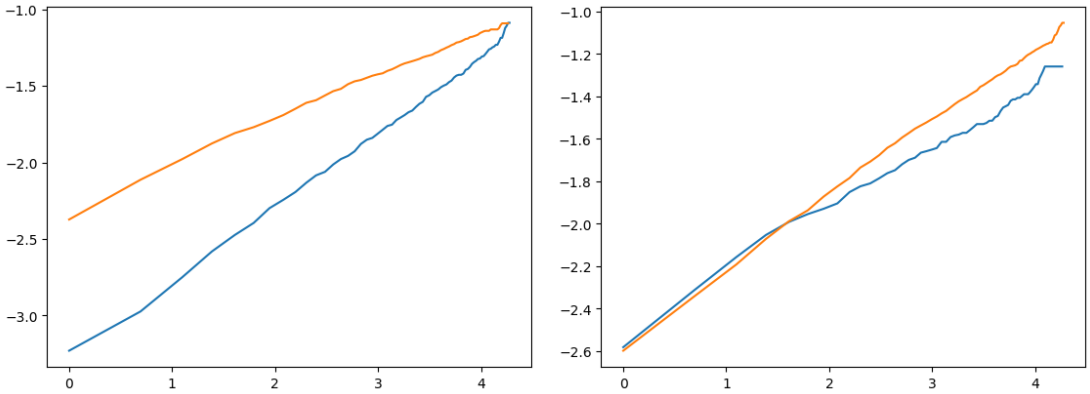

(a) partner (b) internetService

图 21: Kaplan-Meier 分组生存曲线

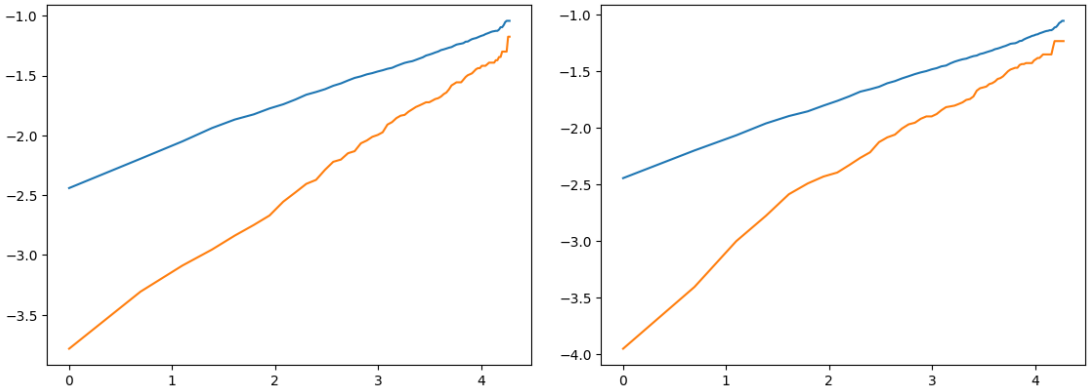

(a) onlineSecurity (b) techSupport

图 22: Log-Odds 检验图（用于验证 Log-Logistic 分布假设）

5.6 Log-Odds 检验（Log-Logistic 分布验证）

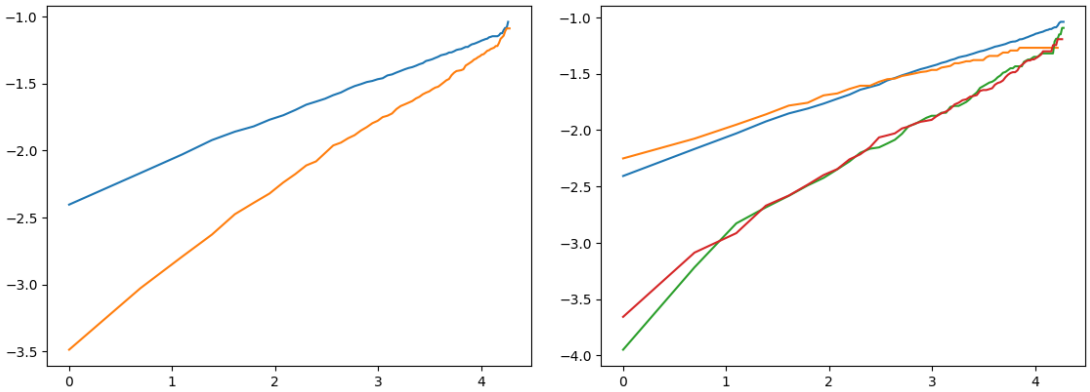

(a) deviceProtection (b) paymentMethod

图 23: Kaplan-Meier 分组生存曲线（续）

如果数据服从 Log-Logistic 分布，ln(odds) vs ln(t) 的曲线应为直线。各变量的曲线大致呈线性关系，支持 Log-Logistic AFT 模型的选择。

6 CLV 与 Payback Period

6.1 计算逻辑

基于 Cox PH 模型的生存概率预测，计算每个合同的月度利润和累积 NPV：

- **月度利润**：$30（固定）
- **月折现率**：年化 IRR 10% 转月度折现率，$r = 10\%/12 \approx 0.833\%$
- **累积 NPV** $= \sum \frac{\text{月利润} \times \text{生存概率}}{(1+\text{月化 IRR})^{\text{月}}}$

6.2 模拟场景

设定客户画像：`internetService_DSL = 1`，`techSupport_Yes = 1`，其余变量为 0。

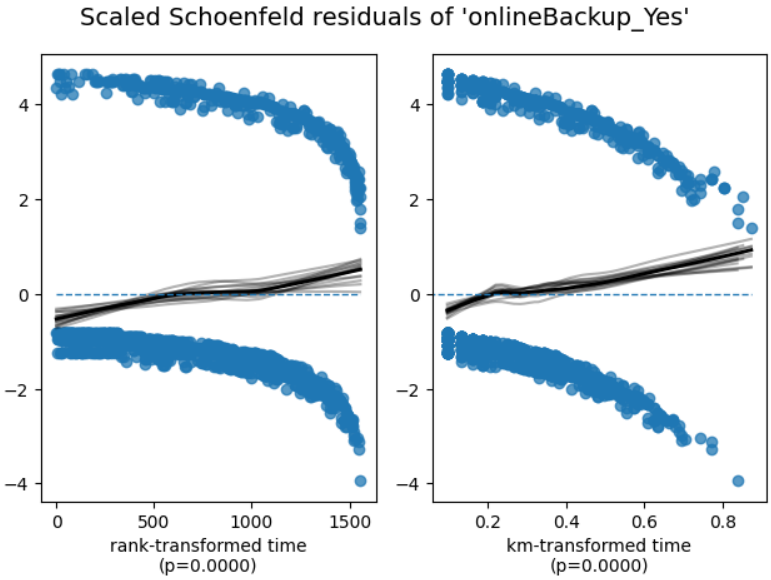

图 24: 生存概率随时间变化曲线

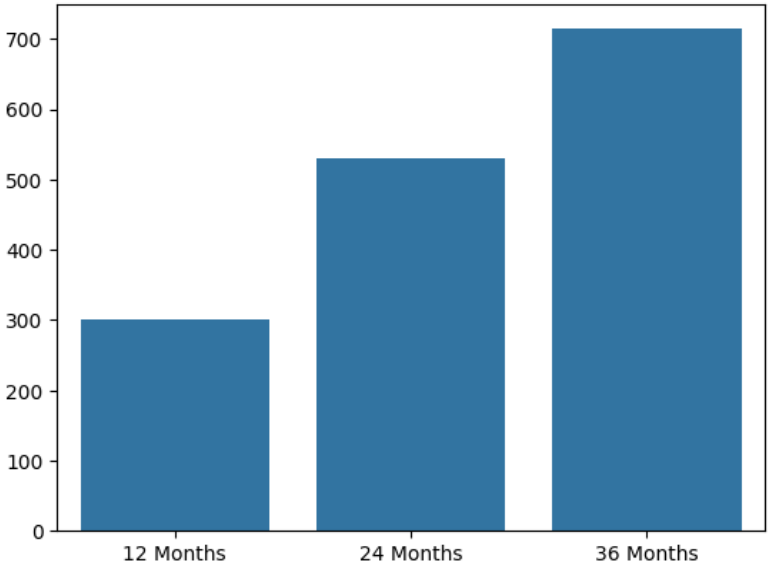

图 25: 12/24/36 个月累积 NPV 柱状图

6.3 月度累积 NPV 数据

合同月	生存概率	月利润	预期月利润	累积 NPV
1	1.00	$30	$30.00	$30.00
2	0.94	$30	$28.20	$57.97
3	0.92	$30	$27.60	$85.12
4	0.90	$30	$27.00	$111.46
5	0.88	$30	$26.40	$137.00
6	0.86	$30	$25.80	$161.75
7	0.85	$30	$25.50	$186.01
8	0.84	$30	$25.20	$209.79
9	0.83	$30	$24.90	$233.09
10	0.82	$30	$24.60	$255.92
11	0.81	$30	$24.30	$278.28
12	**0.80**	**$30**	**$24.00**	**$300.19**
13	0.79	$30	$23.70	$321.64
14	0.78	$30	$23.40	$342.65
15	0.77	$30	$23.10	$363.22
16	0.76	$30	$22.80	$383.35
17	0.75	$30	$22.50	$403.05
18	0.74	$30	$22.20	$422.33
19	0.73	$30	$21.90	$441.19
20	0.73	$30	$21.90	$459.90
21	0.72	$30	$21.60	$478.20
22	0.71	$30	$21.30	$496.09
23	0.71	$30	$21.30	$513.84
24	**0.70**	**$30**	**$21.00**	**$531.19**
25	0.69	$30	$20.70	$548.15

表 23: 月度累积 NPV 数据（DSL + TechSupport 客户场景）

6.4 CLV 关键节点

时间节点	累积 NPV
12 个月	$300.19
24 个月	$531.19
25 个月	$548.15

表 24: 累积 NPV 关键节点

结论：收益增长主要集中在前 12 个月（$300 NPV），之后边际贡献递减。到第 24 个月累积 NPV 为 $531，到第 25 个月仅增加约 $17（$548），说明长期客户的边际价值趋于稳定。

关于投资回收期（Payback Period）：由于月度利润（$30）为正值，累积 NPV 从第 1 个

月起即为正，因此对于本场景不存在传统意义上的投资回收期。若要计算回收期，需先确定客户获取成本（CAC），再在累积 NPV 中扣除该成本后求正的时刻。本报告中未包含 CAC 数据，因此未进行投资回收期的实际计算。

7 方法总结与比较

方法	用途	优势	局限
Kaplan-Meier	非参数估计生存曲线	无分布假设，直观展示生存函数	不能同时纳入多个协变量
Log-Rank Test	检验组间生存差异	简单有效的假设检验	只能用于单变量比较
Cox PH	多变量生存回归	不需指定基线风险函数	要求比例风险假设
AFT (Log-Logistic)	多变量生存时间建模	无比例风险假设要求	需要指定分布类型

表 25: 方法对比

模型选择建议：

- 当比例风险假设成立时，Cox PH 模型是首选（简单高效）。
- 当假设不成立时（如本案例中 `internetService_DSL`、`onlineBackup_Yes`），AFT 模型是更好的选择（本案例中 AFT 的 Concordance 更高：0.73 vs 0.64）。
- 两种模型互补使用可提供更全面的分析视角。

8 结论

1. **Month-to-month 合同且使用互联网服务的客户**（3,351 人）在网初期流失率最高，是重点挽留群体。
2. **在线安全服务、技术支持、在线备份**是降低流失风险的最强保护因子，业务上应鼓励客户订阅这些增值服务。
3. **有伴侣和有家属的客户**留存概率显著更高，可以针对无家属的客户群体设计特定的留存策略。
4. **支付方式对流失有显著影响**，使用自动扣款（Credit card / Bank transfer）的客户留存优于使用 Electronic check 的客户。
5. **Cox PH 模型和 AFT 模型结果一致**：所有纳入的变量均为显著的保护因子，但 AFT 模型因不要求比例风险假设，在本案例中表现更优。
6. **CLV 分析显示**，客户前 12 个月贡献了主要价值（$300 NPV），长期留存客户的价值增量有限，建议将获客和早期挽留作为核心商业策略。